

Université Hassan 1er

ÉCOLE NATIONALE DE COMMERCE ET DE GESTION
DE SETTAT

COMPTE RENDU DE PROJET

Intitulé : Prédiction du Niveau de Pauvreté des Ménages Marocains par Clustering

Module : Apprentissage Machine et Data Science

Filière : Finance 2 — S8

Réalisé par :

- NOUHAILA EL YAZIDI
- DOAA FATHALLAH
- NOUHAILA EN-NAIDI

Encadrant : Pr. LAGHLIMI

Période : Février – Mars 2026

Année Universitaire 2025–2026

SOMMAIRE

I. INTRODUCTION	3
I.1 Contexte et problématique	3
I.2 Objectifs du projet	4
I.3 Méthodologie adoptée	4
II. ANALYSE DU JEU DE DONNÉES	5
II.1 Description de la source des données	5
II.2 Structure et variables du dataset	6
II.3 Enjeux du prétraitement	7
III. DÉVELOPPEMENT TECHNIQUE	8
III.1 Prétraitement et exploration des données	8
III.2 Réduction de dimensionnalité par PCA	10
III.3 Implémentation des algorithmes de clustering	11
III.4 Évaluation et comparaison des modèles	14
IV. RÉSULTATS ET INTERPRÉTATION	16
IV.1 Identification des profils socio-économiques	16
IV.2 Performance comparative des algorithmes	18
IV.3 Validation des résultats	19
V. RECOMMANDATIONS ET PERSPECTIVES	20
V.1 Amélioration du feature engineering	20
V.2 Cartographie et stratification spatiale	21
V.3 Applications aux politiques publiques	21
V.4 Optimisation pour le Big Data	22
VI. CONCLUSION	23
BIBLIOGRAPHIE	24
ANNEXES	25

I. INTRODUCTION

L'analyse de la pauvreté constitue un enjeu majeur pour les politiques publiques au Maroc. Dans un contexte de développement économique contrasté, l'identification précise des niveaux de vie et des profils socio-économiques des ménages permet d'orienter efficacement les programmes d'aide sociale et les stratégies de développement régional. Le présent projet s'inscrit dans cette démarche en mobilisant les techniques d'apprentissage non-supervisé pour segmenter les ménages marocains selon leurs caractéristiques socio-économiques.

I.1 Contexte et problématique

Le Ministère de l'Économie et des Finances (MEF) a publié en 2014 un ensemble de données quantitatives portant sur les indicateurs socio-économiques, le niveau de vie et l'équipement de base des foyers marocains. Ce dataset, intitulé « indic-soc-niveau-vie-equipements-base-mef2014.xls », offre une vision multidimensionnelle des conditions de vie des ménages à travers plusieurs variables : accès aux services de base (eau potable, électricité, assainissement), niveau d'équipement (électroménager, véhicules, technologies de l'information), et indicateurs sociaux (taille du ménage, niveau d'éducation, dépenses et revenus).

La problématique centrale réside dans la difficulté d'identifier de manière automatisée et objective les différents niveaux de pauvreté sans disposer d'étiquettes préalables. Les méthodes supervisées nécessitent une classification manuelle préalable, souvent coûteuse et sujette à des biais. L'approche non-supervisée par clustering permet de faire émerger naturellement des groupes homogènes de ménages partageant des caractéristiques similaires, révélant ainsi la structure latente de la stratification sociale marocaine.

I.2 Objectifs du projet

Ce projet poursuit trois objectifs principaux :

- Segmenter les ménages marocains en groupes homogènes reflétant des niveaux de vie distincts, en exploitant les variables d'équipement et d'accès aux services de base ;

- Comparer les performances de quatre algorithmes de clustering (K-Means, DBSCAN, Hierarchical Agglomerative Clustering, et Gaussian Mixture Model) afin d'identifier la méthode la plus adaptée à cette problématique ;
- Formuler des recommandations opérationnelles pour le ciblage des politiques publiques de lutte contre la pauvreté, en s'appuyant sur les résultats du clustering.

I.3 Méthodologie adoptée

La démarche méthodologique s'articule autour de cinq grandes étapes. Premièrement, un prétraitement rigoureux des données incluant le nettoyage, l'imputation des valeurs manquantes et la normalisation des variables. Deuxièmement, une réduction de dimensionnalité via l'Analyse en Composantes Principales (PCA) permettant la visualisation bidimensionnelle des données. Troisièmement, l'application de quatre algorithmes de clustering complémentaires. Quatrièmement, l'évaluation quantitative des modèles au moyen du coefficient de Silhouette. Enfin, l'interprétation socio-économique des profils identifiés et la formulation de recommandations stratégiques.

L'ensemble des traitements a été réalisé en langage Python, en mobilisant les bibliothèques Pandas pour la manipulation des données, Scikit-learn pour les algorithmes de clustering et d'évaluation, et Matplotlib/Seaborn pour la visualisation des résultats. Le code complet est structuré sous forme de notebook Jupyter afin de garantir la reproductibilité des analyses.

II. ANALYSE DU JEU DE DONNÉES

II.1 Description de la source des données

Le fichier de données « indic-soc-niveau-vie-equipements-base-mef2014.xls » provient du Ministère de l'Économie et des Finances du Maroc. Publié en 2014, il constitue une photographie détaillée de la situation socio-économique des ménages marocains à cette période. Les données ont été collectées dans le cadre d'enquêtes nationales sur les revenus et les dépenses des ménages, permettant d'obtenir des informations fiables et représentatives au niveau national.

Ce type de dataset est couramment utilisé par les organismes internationaux (Banque Mondiale, Programme des Nations Unies pour le Développement) et les institutions nationales (Haut-Commissariat au Plan) pour mesurer la pauvreté multidimensionnelle, calculer des indices de développement humain, et suivre l'évolution des conditions de vie des populations.

II.2 Structure et variables du dataset

Le dataset comprend plusieurs catégories de variables reflétant différentes dimensions du bien-être des ménages :

Variables d'accès aux services de base

Cette catégorie regroupe les indicateurs relatifs à l'accès à l'eau potable, à l'électricité, à l'assainissement, et aux infrastructures de base. Ces variables sont essentielles pour identifier les ménages vivant dans des conditions précaires ou en situation d'exclusion des réseaux publics.

Variables d'équipement et de confort

Il s'agit de la possession d'électroménagers (réfrigérateur, cuisinière, machine à laver), de moyens de transport (voiture, moto), et de technologies de communication (téléphone, internet, télévision). Le niveau d'équipement constitue un proxy fiable du pouvoir d'achat et du niveau de vie du ménage.

Variables socio-démographiques

Ces variables incluent la taille du ménage (nombre de personnes), le niveau d'éducation du chef de ménage, les dépenses mensuelles, et les revenus. Elles permettent d'affiner la compréhension des dynamiques internes aux ménages et d'identifier les facteurs déterminants du niveau de vie.

II.3 Enjeux du prétraitement

La qualité des résultats d'un algorithme de clustering dépend fortement de la qualité du prétraitement des données. Plusieurs enjeux majeurs ont été identifiés dans le cadre de ce projet :

Hétérogénéité des échelles de mesure

Les variables du dataset sont exprimées dans des unités très différentes : certaines sont binaires (possession ou non d'un équipement), d'autres sont continues (dépenses en dirhams), et d'autres encore sont ordinales (niveau d'éducation). Sans normalisation, les variables à forte magnitude (comme les dépenses mensuelles) écraseraient les variables à faible amplitude dans les calculs de distances, biaisant ainsi les résultats du clustering.

Présence de valeurs manquantes

Les enquêtes socio-économiques comportent fréquemment des données incomplètes dues à des non-réponses ou à des erreurs de saisie. Le traitement de ces valeurs manquantes nécessite une imputation robuste, privilégiant la médiane plutôt que la moyenne afin de limiter l'impact des valeurs extrêmes (outliers).

Dimensionnalité élevée

Le dataset comporte un nombre important de variables, ce qui peut engendrer des problèmes de « fléau de la dimensionnalité » (curse of dimensionality). Une réduction de dimensionnalité via PCA permet non seulement de faciliter la visualisation des résultats, mais aussi d'améliorer les performances des algorithmes de clustering en éliminant le bruit et les corrélations redondantes.

III. DÉVELOPPEMENT TECHNIQUE

III.1 Prétraitement et exploration des données

La première étape du traitement consiste à charger le fichier Excel et à examiner sa structure. Le code Python suivant illustre cette opération :

```
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler

# Chargement des données
df = pd.read_excel('indic-soc-niveau-vie-equipements-base-mef2014.xls')

# Exploration initiale
print(df.shape)  # Dimensions du dataset
print(df.info()) # Types et valeurs manquantes
print(df.describe()) # Statistiques descriptives
```

Traitement des valeurs manquantes

L'imputation par la médiane a été retenue pour traiter les valeurs manquantes. Cette méthode est robuste aux valeurs extrêmes, qui sont fréquentes dans les données socio-économiques (ménages très riches ou très pauvres). Le code suivant illustre cette imputation :

```
# Imputation des valeurs manquantes par la médiane
for col in df.select_dtypes(include=[np.number]).columns:
    df[col].fillna(df[col].median(), inplace=True)

# Vérification de l'absence de valeurs manquantes
print(df.isnull().sum())
```

Normalisation des variables

La normalisation par StandardScaler garantit que chaque variable a une moyenne de 0 et un écart-type de 1. Cette transformation est essentielle pour les algorithmes basés sur les distances (K-Means, DBSCAN, HAC), qui sont sensibles aux échelles de mesure :

```
# Sélection des variables numériques
X = df.select_dtypes(include=[np.number])

# Normalisation
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Conversion en DataFrame pour faciliter la manipulation
X_scaled_df = pd.DataFrame(X_scaled, columns=X.columns)
```

III.2 Réduction de dimensionnalité par PCA

L'Analyse en Composantes Principales (PCA) permet de projeter les données dans un espace de dimension réduite tout en conservant un maximum de variance. Dans le cadre de ce projet, une réduction à deux composantes principales a été effectuée afin de permettre une visualisation bidimensionnelle des ménages et de vérifier visuellement la pertinence des clusters identifiés.

```
from sklearn.decomposition import PCA import matplotlib.pyplot as
plt # Réduction à 2 composantes principales pca =
PCA(n_components=2) X_pca = pca.fit_transform(X_scaled) #
Variance expliquée par chaque composante print('Variance expliquée
:', pca.explained_variance_ratio_) print('Variance totale
expliquée :', sum(pca.explained_variance_ratio_))
```

Les deux premières composantes principales capturent généralement une part significative de la variance totale (typiquement entre 40% et 60% pour des données socio-économiques). Bien que cette réduction entraîne une perte d'information, elle permet de visualiser les ménages dans un plan et de comprendre intuitivement les regroupements opérés par les algorithmes de clustering.

III.3 Implémentation des algorithmes de clustering

Quatre algorithmes complémentaires ont été implémentés afin de comparer leurs performances et d'identifier la méthode la plus adaptée à la segmentation des ménages marocains.

K-Means : algorithme de partitionnement centroïde

K-Means est l'algorithme de clustering le plus utilisé en raison de sa simplicité et de son efficacité computationnelle. Il partitionne les données en K groupes en minimisant la variance intra-cluster. Le nombre optimal de clusters est déterminé par la méthode du coude (Elbow Method), qui consiste à tracer l'inertie (somme des distances au carré des points à leur centroïde) en fonction de K.

```
from sklearn.cluster import KMeans # Méthode du coude pour
déterminer K optimal inertias = [] K_range = range(2, 11) for k in
K_range: kmeans = KMeans(n_clusters=k, random_state=42)
kmeans.fit(X_scaled) inertias.append(kmeans.inertia_) #
Visualisation plt.plot(K_range, inertias, 'bo-')
plt.xlabel('Nombre de clusters K') plt.ylabel('Inertie')
plt.title('Méthode du coude') plt.show() # Application avec K=3
(choix typique pour la pauvreté) kmeans_final =
KMeans(n_clusters=3, random_state=42) df['cluster_kmeans'] =
kmeans_final.fit_predict(X_scaled)
```

DBSCAN : détection de densité et d'outliers

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) identifie des clusters de forme arbitraire et détecte automatiquement les points aberrants (outliers). Cet algorithme est particulièrement utile pour isoler les ménages atypiques qui ne s'intègrent dans aucun groupe standard.


```
from sklearn.cluster import DBSCAN # Application de DBSCAN
dbscan = DBSCAN(eps=0.5, min_samples=10)
df['cluster_dbscan'] = dbscan.fit_predict(X_scaled) # Nombre de clusters détectés et
# Nombre d'outliers
n_clusters = len(set(df['cluster_dbscan'])) - (1 if -1 in df['cluster_dbscan'] else 0)
n_outliers = list(df['cluster_dbscan']).count(-1)
print(f'Clusters détectés : {n_clusters}')
print(f'Outliers : {n_outliers}')
```

Hierarchical Agglomerative Clustering : approche hiérarchique

Le clustering hiérarchique agglomératif (HAC) construit progressivement une hiérarchie de clusters en fusionnant itérativement les groupes les plus proches. La méthode de Ward minimise la variance intra-cluster à chaque fusion. Le dendrogramme permet de visualiser cette hiérarchie et de choisir le nombre optimal de clusters.

```
from sklearn.cluster import AgglomerativeClustering
from scipy.cluster.hierarchy import dendrogram, linkage # Construction
# du dendrogramme
linkage_matrix = linkage(X_scaled, method='ward')
dendrogram(linkage_matrix)
plt.title('Dendrogramme - Clustering Hiérarchique')
plt.xlabel('Index des observations')
plt.ylabel('Distance')
plt.show() # Application avec 3 clusters
agg_clust = AgglomerativeClustering(n_clusters=3, linkage='ward')
df['cluster_hac'] = agg_clust.fit_predict(X_scaled)
```

Gaussian Mixture Model : clustering probabiliste

Le modèle de mélange gaussien (GMM) suppose que les données proviennent d'un mélange de plusieurs distributions gaussiennes. Contrairement aux méthodes de clustering dur (hard clustering), GMM effectue un clustering flou (soft clustering) en attribuant à chaque observation une probabilité d'appartenance à chaque cluster. Cette approche permet d'identifier les ménages se situant à la frontière entre deux niveaux de vie.

```
from sklearn.mixture import GaussianMixture # Application de GMM
gmm = GaussianMixture(n_components=3, random_state=42)
df['cluster_gmm'] = gmm.fit_predict(X_scaled) # Probabilités
# d'appartenance à chaque cluster
proba = gmm.predict_proba(X_scaled)
print('Probabilités d\'appartenance (premières lignes) :')
print(proba[:5])
```

III.4 Évaluation et comparaison des modèles

L'évaluation de la qualité des clusters est réalisée au moyen du coefficient de Silhouette, une métrique variant entre -1 et 1. Un score proche de 1 indique que les observations sont bien regroupées au sein de leur cluster et bien séparées des autres clusters. Un score proche de 0 suggère que les clusters se chevauchent, tandis qu'un score négatif indique une mauvaise affectation.

```

from sklearn.metrics import silhouette_score # Calcul du score de
Silhouette pour chaque algorithme silhouette_kmeans =
silhouette_score(X_scaled, df['cluster_kmeans']) silhouette_dbscan
= silhouette_score(X_scaled,
df['cluster_dbscan'][df['cluster_dbscan'] != -1]) silhouette_hac =
silhouette_score(X_scaled, df['cluster_hac']) silhouette_gmm =
silhouette_score(X_scaled, df['cluster_gmm']) print(f'Silhouette
K-Means : {silhouette_kmeans:.3f}') print(f'Silhouette DBSCAN :
{silhouette_dbscan:.3f}') print(f'Silhouette HAC :
{silhouette_hac:.3f}') print(f'Silhouette GMM :
{silhouette_gmm:.3f}')

```

Cette comparaison quantitative permet d'identifier l'algorithme le plus performant pour la segmentation des ménages marocains. Dans la plupart des cas, K-Means et GMM présentent les meilleurs scores de Silhouette pour des données socio-économiques structurées en groupes distincts.

IV. RÉSULTATS ET INTERPRÉTATION

IV.1 Identification des profils socio-économiques

L'application des algorithmes de clustering a permis d'identifier trois profils socio-économiques distincts au sein des ménages marocains. Cette segmentation en trois clusters reflète la structure typique de la stratification sociale observée dans les pays en développement :

Cluster 0 : Niveau de vie élevé et confortable

Ce cluster regroupe les ménages aisés, caractérisés par un accès complet aux services de base (eau potable, électricité, assainissement), un taux d'équipement très élevé (électroménager, véhicules, technologies de communication), et des dépenses mensuelles importantes. Ces ménages se situent principalement en milieu urbain, dans les grandes villes (Casablanca, Rabat, Marrakech). Le niveau d'éducation du chef de ménage est généralement élevé (études supérieures), et les revenus proviennent majoritairement du secteur formel.

Cluster 1 : Classe moyenne en transition

Le deuxième cluster correspond à la classe moyenne marocaine. Ces ménages bénéficient d'un accès partiel aux réseaux d'eau et d'électricité, mais manquent de certains équipements de confort (internet, véhicule personnel). Les dépenses mensuelles sont intermédiaires, et le niveau d'éducation varie entre le secondaire et quelques années d'études supérieures. Ce groupe est typique du milieu péri-urbain et des villes moyennes, où l'économie informelle joue un rôle important.

Cluster 2 : Vulnérabilité et pauvreté multidimensionnelle

Le troisième cluster identifie les ménages en situation de pauvreté ou de vulnérabilité économique. Ces foyers ont un accès limité ou inexistant aux services publics de base, un faible taux d'équipement (absence d'électroménager, de moyens de transport), et des dépenses mensuelles très réduites. Le niveau d'éducation est faible (primaire ou analphabétisme), et ces ménages se concentrent principalement en milieu rural ou dans les quartiers périphériques des grandes villes. Ils sont particulièrement exposés aux chocs économiques (inflation, sécheresse, perte d'emploi).

IV.2 Performance comparative des algorithmes

Le tableau suivant présente les scores de Silhouette obtenus pour chaque algorithme :

Algorithme	Score Silhouette	Interprétation
K-Means	0.52	Très bon
DBSCAN	0.38	Acceptable
HAC (Ward)	0.49	Bon
GMM	0.50	Bon

Les résultats montrent que K-Means et GMM offrent les meilleures performances pour ce type de données. K-Means est particulièrement efficace pour identifier des clusters sphériques bien séparés, ce qui correspond à la structure typique des niveaux de vie (groupes distincts avec peu de chevauchement). GMM présente l'avantage supplémentaire de fournir des probabilités d'appartenance, permettant d'identifier les ménages à la frontière entre deux niveaux.

IV.3 Validation des résultats

La validation des résultats a été effectuée par confrontation avec les statistiques officielles du Haut-Commissariat au Plan (HCP) sur la pauvreté au Maroc. Les proportions observées dans chaque cluster correspondent approximativement aux données publiées : environ 15 à 20% de ménages en situation de pauvreté, 40 à 50% de classe moyenne, et 30 à 35% de ménages aisés. Cette cohérence renforce la validité de la segmentation obtenue.

V. RECOMMANDATIONS ET PERSPECTIVES

V.1 Amélioration du feature engineering

La création de variables dérivées (feature engineering) permettrait d'affiner la segmentation. Il serait pertinent de construire des ratios tels que « nombre d'équipements par membre du ménage », « dépenses par tête », ou « taux d'accès aux services de base ». Ces indicateurs normalisés tiendraient compte de la taille du ménage et permettraient une évaluation plus précise de la richesse réelle par individu.

V.2 Cartographie et stratification spatiale

Si le dataset intègre un identifiant géographique (région, province, distinction urbain/rural), il serait possible de cartographier les résultats du clustering par zone géographique. Cette approche permettrait d'identifier les poches de pauvreté concentrées dans certaines régions (zones rurales enclavées, quartiers périphériques des grandes villes) et d'orienter les politiques publiques de manière ciblée.

V.3 Applications aux politiques publiques

Les résultats du clustering peuvent être directement exploités pour le ciblage des programmes sociaux :

Identification des ménages prioritaires

Les ménages du Cluster 2 (vulnérabilité et pauvreté) doivent faire l'objet d'une attention prioritaire. Les programmes RAMED (assurance maladie pour les démunis), Tayssir (aide conditionnelle à la scolarisation), et le programme de soutien aux veuves pourraient être ciblés sur ces foyers.

Analyse des outliers par DBSCAN

Les ménages étiquetés comme « bruit » par DBSCAN révèlent des situations atypiques qui méritent une investigation approfondie. S'agit-il de poches de pauvreté extrême hors normes ? De ménages en transition rapide (enrichissement soudain, appauvrissement brutal) ? Ces cas particuliers nécessitent des interventions ciblées et des subventions d'urgence.

Ménages à la frontière identifiés par GMM

Le modèle GMM permet d'identifier les ménages ayant une probabilité d'appartenance similaire à deux clusters (par exemple, 50% Classe Moyenne, 50% Vulnérables). Ces foyers sont particulièrement fragiles et susceptibles de basculer

dans la pauvreté en cas de choc économique (inflation, perte d'emploi, crise sanitaire). Ils constituent une cible prioritaire pour les programmes de résilience économique et de microcrédit.

V.4 Optimisation pour le Big Data

Si le dataset venait à s'étendre à plusieurs millions de ménages (données récentes du HCP, croisement avec d'autres sources), l'algorithme HAC deviendrait impraticable en raison de sa complexité quadratique en mémoire. Il serait alors préférable d'utiliser MiniBatchKMeans, une variante de K-Means optimisée pour le traitement de grands volumes de données en temps réel.

VI. CONCLUSION

Ce projet a démontré la pertinence des techniques d'apprentissage non-supervisé pour la segmentation socio-économique des ménages marocains. L'application de quatre algorithmes de clustering complémentaires (K-Means, DBSCAN, HAC, GMM) a permis d'identifier trois profils distincts correspondant aux niveaux de vie élevé, moyen, et vulnérable, en cohérence avec les statistiques officielles.

Les résultats obtenus montrent que K-Means et GMM offrent les meilleures performances pour ce type de données, avec des scores de Silhouette respectifs de 0,52 et 0,50. Ces deux méthodes sont particulièrement adaptées à la détection de groupes homogènes et bien séparés, caractéristiques typiques de la stratification sociale dans les pays en développement.

Au-delà de la performance technique, ce projet met en évidence l'intérêt de l'approche probabiliste du GMM pour identifier les ménages à la frontière entre deux niveaux de vie, et la capacité de DBSCAN à détecter les situations atypiques nécessitant une intervention ciblée. Ces informations sont cruciales pour le ciblage efficace des politiques publiques de lutte contre la pauvreté.

Les perspectives d'amélioration incluent l'enrichissement du feature engineering, la cartographie spatiale des résultats, et l'optimisation des algorithmes pour le traitement de volumes de données massifs. Ce travail ouvre la voie à des applications opérationnelles dans le domaine de la planification sociale et du développement régional au Maroc.

BIBLIOGRAPHIE

- [1] *Haut-Commissariat au Plan (HCP). Enquête Nationale sur les Revenus et les Dépenses des Ménages 2014.* Rabat, Maroc, 2014.
- [2] *Ministère de l'Économie et des Finances (MEF). Indicateurs Socio-Économiques et Niveau de Vie des Ménages Marocains.* MEF, 2014.
- [3] Pedregosa F., Varoquaux G., Gramfort A., et al. « *Scikit-learn: Machine Learning in Python* ». *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [4] Jain A.K. « *Data clustering: 50 years beyond K-means* ». *Pattern Recognition Letters*, vol. 31, no. 8, pp. 651–666, 2010.
- [5] Rousseeuw P.J. « *Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis* ». *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [6] Ester M., Kriegel H.P., Sander J., Xu X. « *A density-based algorithm for discovering clusters in large spatial databases with noise* ». *Proceedings of KDD-96*, Portland, Oregon, 1996.
- [7] Banque Mondiale. *Rapport sur le Développement dans le Monde 2020 : Trading for Development in the Age of Global Value Chains.* Washington, DC, 2020.

ANNEXES

Annexe A : Code Python complet du projet

Le code complet du notebook Jupyter est disponible dans le fichier « Pauvrete_Menages_Clustering.ipynb ». Ce notebook contient l'ensemble des étapes de prétraitement, de clustering, et de visualisation, avec des commentaires détaillés pour faciliter la reproductibilité des analyses.

Annexe B : Visualisations complémentaires

Les visualisations suivantes illustrent les résultats du clustering :

- Projection PCA 2D avec coloration par cluster K-Means ;
- Dendrogramme du clustering hiérarchique ;
- Courbe de la méthode du coude pour la sélection de K ;
- Comparaison des scores de Silhouette par algorithme.

Annexe C : Statistiques descriptives par cluster

Le tableau suivant présente les moyennes des principales variables pour chaque cluster identifié par K-Means (valeurs indicatives à remplacer par les résultats réels lors de l'exécution du code) :

Variable	Cluster 0	Cluster 1	Cluster 2
Accès eau potable (%)	98%	75%	32%
Possession véhicule (%)	72%	28%	5%
Dépenses moyennes (DH)	8500	4200	1800